ERSD
EARTH SCIENCES AND NATURAL RESOURCES FOR SUSTAINABLE DEVELOPMENT

1966 - 2026
TRƯỜNG ĐẠI HỌC MỎ - ĐỊA CHẤT

HỘI NGHỊ KHOA HỌC ERSD 2026

SỬ DỤNG PYTHON XỬ LÝ DỮ LIỆU CHỈ TIÊU CƠ LÝ ĐẤT ĐỂ CHUẨN BỊ DỮ LIỆU HUẤN LUYỆN AI

Ngô Thị Phương Thảo, Ngô Hùng Long, Nguyễn Thị Hải Yến

Trường Đại học Mỏ – Địa chất

1966 – 2026 · 60 năm Trường Đại học Mỏ – Địa chất

166 tệp đầu vào **963** sheet **20.532** mẫu hợp lệ

00 | NỘI DUNG TRÌNH BÀY

Bốn phần của báo cáo

01 **Đặt vấn đề**

Vì sao dữ liệu Excel lịch sử khó đưa vào pipeline AI?

02 **Phương pháp**

Thu thập – phân tích – lập trình – kiểm chứng

03 **Kết quả**

Định lượng, định tính và thảo luận

04 **Kết luận**

Bài học, hạn chế và hướng phát triển

Dữ liệu địa kỹ thuật lịch sử: giàu số liệu, nghèo tính nhất quán

01

Dữ liệu phân tán

166 workbook, nhiều sheet trong mỗi hồ sơ; trộn .xls, .xlsx và cả tên dạng .xls.xlsx.

02

Lỗi bảng mã

Văn bản soạn bằng TCVN3 / font .Vn… bị sai dấu khi đọc hoặc ghi ra, cản trở ghép nối pipeline.

03

Cấu trúc không đồng nhất

Vùng bảng, dòng tiêu đề, đơn vị và tên chỉ tiêu thay đổi theo từng đơn vị soạn thảo.

Cần một quy trình tự động, tái lập: chuẩn hóa mã ký tự + tách sheet + xuất CSV → sẵn sàng cho AI

01 | MỤC TIÊU

Bốn mục tiêu của nghiên cứu

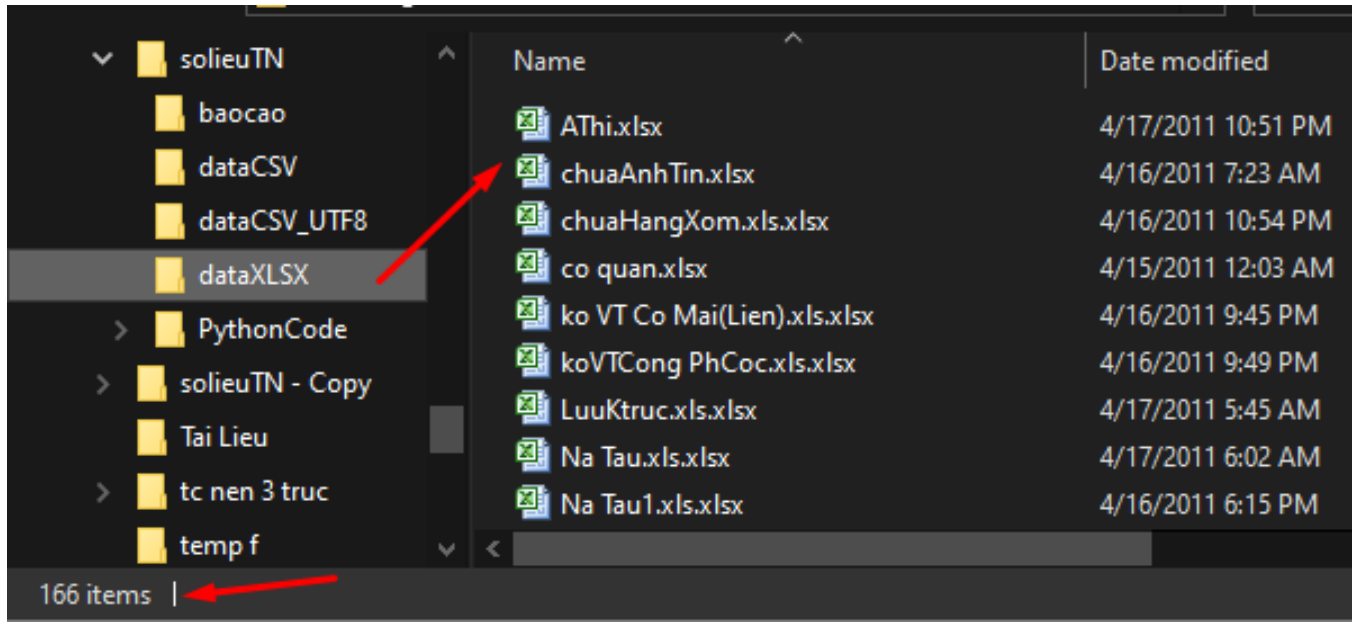
01	**Quét hàng loạt**	Duyệt toàn bộ .xls / .xlsx trong thư mục cấu hình, không sửa mã khi thêm hồ sơ mới.
02	**Chuẩn hóa tiếng Việt**	Nhận diện TCVN3 theo font và mẫu ký tự, chuyển sang Unicode chuẩn.
03	**Xuất dữ liệu phẳng**	Mỗi sheet có dữ liệu → một CSV UTF-8, tên file_sheet, bỏ sheet rỗng.
04	**Kiểm soát chất lượng**	Ghi nhận tệp lỗi, bảo đảm kết quả lặp lại và truy vết được nguồn.

KẾT QUẢ KỲ VỌNG

Một pipeline Python

có thể tái sử dụng, tạo tập dữ liệu sạch cho gắn nhãn và huấn luyện mô hình.

166 tệp bảng tính từ nhiều hồ sơ khảo sát



Hình 1. Thư mục dataXLSX với 166 tệp .xls / .xlsx

166

TỆP ĐẦU VÀO

158 .xlsx + 8 .xls

963

SHEET CÓ DỮ LIỆU

sau khi loại sheet rỗng

20.532

MẪU HỢP LỆ

dùng làm đầu vào huấn luyện

Nguồn: hồ sơ khảo sát địa kỹ thuật, thí nghiệm đất của nhiều công trình; nhiều văn bản gốc dùng bảng mã TCVN3.

TCVN3 không phải Unicode: cần ánh xạ tường minh

VẤN ĐỀ

Cùng một chuỗi tiếng Việt, TCVN3 lưu bằng các ký tự Latin / ký hiệu khác Unicode. Nếu chỉ đọc–ghi mà không chuyển mã, dấu tiếng Việt sẽ sai hoặc mất.

TCVN3

b¸o c¸o kÕt qu¶ thÝ nghiÖm ®Êt

UNICODE

báo cáo kết quả thí nghiệm đất

Chuyển đổi một chiều: thứ tự ánh xạ là kinh nghiệm thực tế, không phải thứ tự alphabet.

BẢNG ÁNH XẠ VIETKEY (TRÍCH)

```
("Aµ", "À"),   ("A¸", "Á"),   ("¢", "Â"),
("EÌ", "È"),   ("EÐ", "É"),   ("£", "Ê"),
("µ", "à"),    ("¸", "á"),    ("©", "â"),
("¡", "Ă"),    ("§", "Đ"),    ("¥", "Ơ"),
("I×", "Ì"),   ("IÝ", "Í"),   ("Oß", "Ò"),
("Oã", "Ó"),   ("Uï", "Ù"),   ("Uó", "Ú"),
("Yý", "Ý"),   ("¦", "Ư"),    ("¨", "ă"),
("ª", "ấ"),    ("Ç", "ầ"),    ("è", "ố"),
```

```
27  _TCVN3_UNICODE_PAIRS: list[tuple[str, str]] = [
28      # Nguồn mapping: vietnamese-conversion (TCVN3 chuẩn VietKey).
29      ("Aµ", "À"),
30      ("A¸", "Á"),
31      ("¢", "Â"),
32      ("A·", "Ã"),
33      ("EÌ", "È"),
34      ("EÐ", "É"),
35      ("£", "Ê"),
```

Hình 3. Trích đoạn bảng ánh xạ trong mã nguồn

Bốn bước logic, một vòng lặp kiểm chứng

01

Thu thập dữ liệu

Quét toàn bộ .xls/.xlsx trong thư mục cấu hình; bỏ PDF, ảnh quét.

→ danh sách tệp

02

Phân tích dữ liệu

Kiểm tra sheet, phạm vi ô, font TCVN3, sheet rỗng và tệp lỗi.

→ workbook + font

03

Lập trình xử lý

Openpyxl / xlrd; chuyển mã 2 pha; xuất CSV UTF-8 có BOM.

→ CSV UTF-8

04

Kiểm chứng

Đếm CSV, đối chiếu chuỗi ngẫu nhiên, chạy lặp lại trên cùng bộ dữ liệu.

→ báo cáo OK/FAIL

Đầu ra của bước trước là đầu vào của bước sau — toàn bộ quy trình chạy batch, không sửa mã nguồn khi thêm hồ sơ.

02 | PIPELINE XỬ LÝ

Sáu bước từ workbook đến CSV UTF-8

01 Quét thư mục
.xls / .xlsx

02 Đọc workbook
openpyxl / xlrd

03 Nhận diện TCVN3
font + mẫu ký tự

04 Chuyển Unicode
thay thế 2 pha

05 Lọc sheet rỗng
không có dữ liệu

06 Xuất CSV UTF-8
utf-8-sig

ĐẦU VÀO

166 tệp
158 .xlsx + 8 .xls

XỬ LÝ

963 sheet
lọc bỏ sheet rỗng

ĐẦU RA

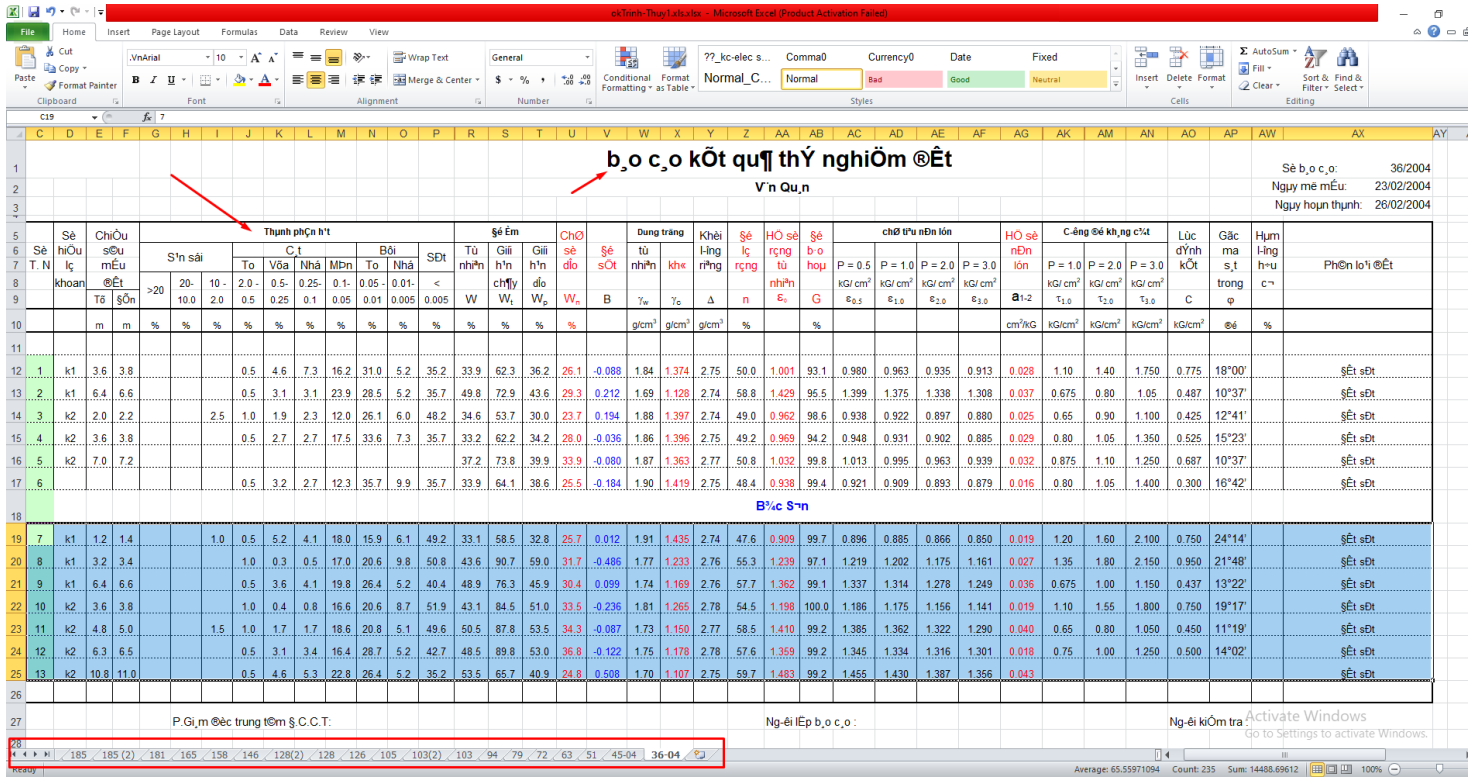
20.532 mẫu
CSV mã UTF-8

NGUYÊN TẮC

Batch
Tái lập
Có log lỗi

Mỗi sheet hợp lệ → 1 tệp CSV; tên file truy vết nguồn; log OK/FAIL cho từng workbook.

Mỗi workbook là một cấu trúc riêng cần kiểm tra



Hình 2. Workbook nhiều sheet, bảng số liệu và lỗi font TCVN3

Cấu trúc

max_row, max_column; sheet rỗng hoặc trang bìa bị loại.

Kiểu dữ liệu

Giữ nguyên giá trị số; chuỗi chỉ chuyển mã khi cần.

Nhận diện TCVN3

Theo font .Vn… / TCVN3 hoặc mẫu ký tự đặc trưng.

Tệp hỏng / có mật khẩu → ghi log, loại khỏi tập huấn luyện.

Một điểm vào, hai thư viện đọc Excel, một định dạng ra

GIAO DIỆN DÒNG LỆNH

```
PowerShell / CMD

python Xlsx2CSV.py \
  --input  "..\dataXLSX" \
  --output "..\dataCSV"

OK: AThi.xls        FAIL: file_hong.xlsx
```

Tham số

`--input` thư mục chứa .xls/.xlsx (mặc định dataXLSX)
`--output` thư mục ghi CSV (mặc định dataCSV)
`stdout` chuẩn hóa UTF-8 trên Windows

XLSX

openpyxl

load_workbook(data_only=True); đọc giá trị đã tính, không tự đánh giá công thức.

XLS

xlrd 1.2.0

formatting_info=True để truy ra tên font; hỗ trợ nhận diện TCVN3.

CSV

csv + utf-8-sig

Ghi UTF-8 có BOM; mở đúng trong Excel và đọc tốt bằng pandas.

Thiếu thư viện / sai phiên bản → báo lỗi kèm hướng dẫn cài đặt.

Thay thế hai pha để không chồng lấn ký tự

01 **Sắp xếp ánh xạ**

Ưu tiên cụm dài trước cụm ngắn; thứ tự kiểm chứng bằng thực nghiệm, không theo alphabet.

02 **Pha 1 — placeholder**

Mỗi chuỗi nguồn được thay bằng ::i:: để cô lập, tránh thay lặp hoặc đè lẫn.

03 **Pha 2 — Unicode**

Thay từng placeholder bằng ký tự đích; chuỗi sau chuyển mã giữ nguyên số và dấu câu.

Điều kiện áp dụng: font TCVN3 hoặc chuỗi có marker đặc trưng.

MÃ GIẢ

two_phase_replace.py

```
for i, (src, dst) in enumerate(pairs):
    text = text.replace(src, f'::{i}::')

for i, (src, dst) in enumerate(pairs):
    text = text.replace(f'::{i}::', dst)
```

Vì chuyển đổi là một chiều và có thể trùng với mã đã có, cần kiểm chứng thứ tự bằng dữ liệu thật trước khi mở rộng bảng ánh xạ.

Kết quả: b¸o c¸o kÕt qu¶ → báo cáo kết quả

Mỗi sheet là một đơn vị truy vết độc lập

QUY ƯỚC TÊN

`TH bc vo.xls_6445.csv` tên_file_gốc + tên_sheet + .csv

✓ **Bỏ sheet rỗng**

Sheet không có ô dữ liệu khả dụng sẽ không tạo CSV.

✓ **Làm sạch tên**

Loại ký tự không hợp lệ trên Windows, giới hạn độ dài hợp lý.

✓ **UTF-8 có BOM**

Mở đúng tiếng Việt trong Excel; đọc tốt bằng pandas.

✓ **Giữ cấu trúc lưới**

Hàng/cột và ô trống được bảo toàn để truy vết nguồn.

write_csv.py

```
with path.open('w', newline='',
               encoding='utf-8-sig') as f:
    w = csv.writer(f)
    for r in rows:
        w.writerow(['' if v is None else v
                    for v in r])
```

Ô None → ô trống; không tự ý đổi kiểu số hay đơn vị.

Định lượng bằng số tệp, định tính bằng chuỗi tiếng Việt

01 Định lượng

Đếm số CSV tạo ra tương ứng số sheet có dữ liệu; so sánh với 166 tệp đầu vào.

02 Định tính

Đối chiếu ngẫu nhiên nội dung CSV với bản gốc; kiểm tra các cụm tiếng Việt sau chuyển mã.

03 Xử lý lỗi

Tệp hỏng hoặc có mật khẩu được ghi log, bỏ qua và tiếp tục các tệp còn lại.

04 Tái lập

Chạy lại trên cùng bộ dữ liệu cho kết quả đồng nhất; phục vụ báo cáo khoa học.

Kết quả kiểm chứng: 166/166 tệp xử lý thành công · 0 tệp lỗi trên bộ dữ liệu thử nghiệm

Cảnh báo metadata (vùng in, header/footer) không làm sai lệch giá trị ô dữ liệu.

03 | KẾT QUẢ ĐỊNH LƯỢNG

Quy mô dữ liệu sau chuẩn hóa

166/166

TỆP XỬ LÝ THÀNH CÔNG

Tỷ lệ thành công 100% trên bộ dữ liệu thử nghiệm

963

SHEET CÓ DỮ LIỆU

Mỗi sheet hợp lệ tạo một tệp CSV riêng

20.532

MẪU HỢP LỆ

Sẵn sàng cho gắn nhãn và huấn luyện AI



TỆP ĐẦU VÀO

166 / 166 tệp

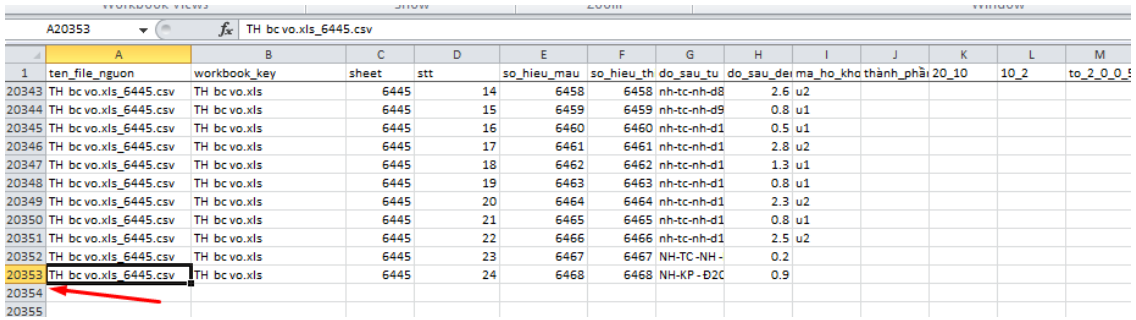
SHEET CÓ DỮ LIỆU

963 sheet → 963 CSV

Ý NGHĨA

Hơn 20 nghìn mẫu đủ lớn để huấn luyện mô hình AI có độ tin cậy; dữ liệu đã thống nhất mã ký tự và định dạng.

Tiếng Việt đọc đúng, cấu trúc lưới được bảo toàn



A20353 | TH bc vo.xls_6445.csv

	A	B	C	D	E	F	G	H	I	J	K	L	M
1	ten_file_nguon	workbook_key	sheet	stt	so_hieu_mau	so_hieu_th	do_sau_tu	do_sau_de	ma_ho_kho	thanh_phai	20_10	10_2	to_2_0_5
20343	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	14	6458	6458	nh-tc-nh-d8	2.6	u2				
20344	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	15	6459	6459	nh-tc-nh-d9	0.8	u1				
20345	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	16	6460	6460	nh-tc-nh-d1	0.5	u1				
20346	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	17	6461	6461	nh-tc-nh-d1	2.8	u2				
20347	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	18	6462	6462	nh-tc-nh-d1	1.3	u1				
20348	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	19	6463	6463	nh-tc-nh-d1	0.8	u1				
20349	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	20	6464	6464	nh-tc-nh-d1	2.3	u2				
20350	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	21	6465	6465	nh-tc-nh-d1	0.8	u1				
20351	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	22	6466	6466	nh-tc-nh-d1	2.5	u2				
20352	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	23	6467	6467	NH-TC-NH-	0.2					
20353	TH bc vo.xls_6445.csv	TH bc vo.xls	6445	24	6468	6468	NH-KP-Đ2C	0.9					
20354													
20355													

Hình 5. AllData.csv sau chuẩn hóa font và cột dữ liệu

ĐỐI CHIẾU TCVN3 → UNICODE

b¸o c¸o kÕt qu¶	→ **báo cáo kết quả**
C«ng tr×nh	→ **Công trình**
§é Èm tù nhi³n	→ **Độ ẩm tự nhiên**
Gãc ma s¸t trong	→ **Góc ma sát trong**

Chuỗi sau chuyển mã hiển thị đúng Unicode; giảm nhiễu ngôn ngữ cho bước gắn nhãn và huấn luyện.

CSV vẫn giữ cấu trúc lưới gần với sheet gốc.

03 | THẢO LUẬN

Điểm mạnh đã kiểm chứng và giới hạn cần tiếp tục

ƯU ĐIỂM

- ✓ Tự động hóa toàn thư mục, giảm thời gian so với xử lý thủ công.
- ✓ UTF-8 thống nhất; đọc tốt bằng Excel, pandas và các pipeline ML.
- ✓ Tên file truy vết nguồn; bỏ sheet rỗng, giảm nhiễu tập huấn luyện.
- ✓ Nhận diện TCVN3 lai (font + mẫu ký tự), giảm bỏ sót.

HẠN CHẾ & RỦI RO

- ! Tệp hỏng hoặc mã hóa mật khẩu cần can thiệp thủ công.
- ! Chưa có schema cột thống nhất giữa các đơn vị soạn thảo.
- ! Chưa kiểm tra đơn vị, phát hiện ngoại lệ số tự động.
- ! Chưa gắn nhãn / huấn luyện mô hình trong phạm vi bài báo.

04 | KẾT LUẬN

Ba kết quả chính và một hướng đi tiếp

01

Pipeline ổn định

Đã xây dựng quy trình Python chạy batch, tách sheet và xuất CSV UTF-8; có thể tái sử dụng cho hồ sơ mới.

02

Chuẩn hóa tiếng Việt

TCVN3 → Unicode theo bảng VietKey, nhận diện lai font + mẫu ký tự, giảm sai lệch do lỗi font.

03

Dữ liệu sẵn sàng

166/166 tệp thành công; 963 sheet; 20.532 mẫu hợp lệ — nền tảng cho gắn nhãn và huấn luyện AI.

THÔNG ĐIỆP

Dữ liệu lịch sử có thể trở thành tài sản AI — nếu được chuẩn hóa đúng cách.

Python là cầu nối.

Từ CSV sạch đến mô hình dự báo chỉ tiêu cơ lý

01 Schema chuẩn

Ánh xạ từng loại sheet sang bảng huấn luyện với cột chỉ tiêu cố định.

02 Kiểm soát chất lượng

Kiểm tra khoảng giá trị, đơn vị, phát hiện ngoại lệ và giá trị thiếu.

03 Pipeline ML

pandas → scikit-learn / PyTorch; theo dõi phiên bản dữ liệu và kết quả.

04 Báo cáo tự động

Xuất log số tệp, tỷ lệ lỗi, metadata phục vụ công bố và tái lập.

Mục tiêu tiếp theo: chuẩn hóa schema và kiểm soát chất lượng số trước khi huấn luyện mô hình dự báo.

ERSD
EARTH SCIENCES AND NATURAL RESOURCES FOR SUSTAINABLE DEVELOPMENT

1966 - 2026
TRƯỜNG ĐẠI HỌC MỎ - ĐỊA CHẤT

ERSD 2026 · PHIÊN THẢO LUẬN

Xin cảm ơn!

Rất mong nhận được câu hỏi và góp ý của quý thầy cô, các đại biểu.

Ngô Thị Phương Thảo · Trường Đại học Mỏ – Địa chất

Sử dụng Python xử lý dữ liệu chỉ tiêu cơ lý đất để chuẩn bị dữ liệu huấn luyện AI

166 tệp **963** sheet **20.532** mẫu hợp lệ